Tháng 10, 2026

PHẦN 1 • BÁO CÁO CHUYÊN ĐỀ

NỀN TẢNG DỮ LIỆU

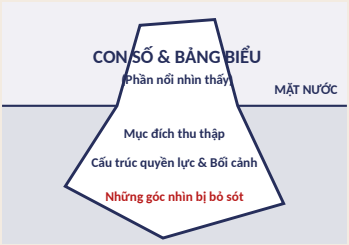
THU THẬP, LÀM SẠCH & CHUẨN HÓA

Từ Dữ Liệu Thô Đến Phép So Sánh Công Bằng (Chương 3, 4, 5)

Thuyết trình: **Người 1** • Tác phẩm: *Hands-On Data Visualization* (Jack Dougherty & Ilya Ilyankou)

DỮ LIỆU KHÔNG BAO GIỜ TRUNG LẬP

1. **Sự ngộ nhận về "Tính khách quan"**
   - Nhiều người lầm tưởng *"con số không biết nói dối"*.
   - Thực tế: Dữ liệu luôn do con người thu thập vì mục đích cụ thể.
   - Chịu chi phối sâu sắc bởi bối cảnh lịch sử và cấu trúc quyền lực.
2. **5 câu hỏi định hướng cốt lõi**
   - Mình muốn trả lời câu hỏi gì?
   - Ai có thể đã thu thập?
   - Dữ liệu chi tiết đến đâu?
   - Ai từng dùng dữ liệu này?
   - Nếu chưa ai thu thập?



Sơ đồ Tảng băng trôi: Dữ liệu luôn có phần chìm chi phối.

DỮ LIỆU CÔNG KHAI VS. RIÊNG TƯ

Khía cạnh	Khu vực Tư nhân (Big Tech)	Khu vực Công (Chính phủ)
Thực trạng thu thập	**Chủ nghĩa tư bản giám sát** (Shoshana Zuboff): Google (cookie), Amazon (Alexa), Meta (theo dõi hành vi).	Dữ liệu công dân; công chúng dùng **Đạo luật Tự do Thông tin (FOIA)** / Sunshine Laws để giám sát.
Dữ liệu cấm công khai cá nhân	Phụ thuộc chính sách nội bộ và đạo luật người tiêu dùng (CCPA).	• **HIPAA:** Bảo mật hồ sơ bệnh án. • **FERPA:** Bảo mật điểm học tập. → *Bắt buộc ẩn danh hóa & gom cụm.*
Dữ liệu cá nhân công khai vì cộng đồng	Dữ liệu di chuyển tổng hợp (Apple Mobility Index trong đại dịch).	1. Đóng góp tài chính bầu cử (FEC). 2. Hồ sơ sở hữu và giá trị bất động sản. 3. Lương lãnh đạo quỹ phi lợi nhuận (IRS 990). 4. Hồ sơ cảnh sát dùng vũ lực (The Force Report).

BẢO VỆ DANH TÍNH: LÀM MỜ & TỔNG HỢP

Để đảm bảo **tính minh bạch, độ tin cậy và khả năng tái lập** , hãy rèn luyện 3 thói quen ngay khi tải file:

1. Đặt tên file có ý nghĩa (Meaningful Filenames)

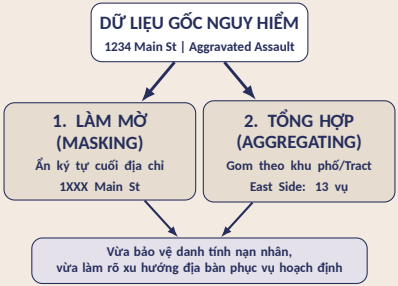
- **Tránh:** `data.csv`, `download.xlsx`, `file(1).csv`.
- **Chuẩn:** Nguồn + Chủ đề + Ngày `YYYY-MM-DD` (chữ thường, gạch nối): `eurostat-co2-emissions-2020-05-01.xlsx`.

2. Tạo tab `notes` riêng biệt bên trong bảng tính

- Ghi rõ cơ quan ban hành, URL tải, định nghĩa nhãn viết tắt, người tải và ngày cập nhật.

3. Tạo tab `backup` bất khả xâm phạm

- Giữ nguyên dữ liệu gốc, thao tác làm sạch ở tab `data`.



4 DẤU HIỆU DỮ LIỆU LỖI KINH ĐIỂN

1. Missing Values Nhập Sai

Ô trống (`null/blank`) có ý nghĩa khác số 0.

Cảnh báo: Người nhập điền 0, −1, −999 để báo khuyết làm sai lệch hoàn toàn hàm `SUM`, `AVERAGE`!

2. Mất Số 0 Dẫn Đầu (Leading Zeros)

Xảy ra khi phần mềm tự ép kiểu Text sang Number.

Hậu quả: Mã Zip 06106 bị biến thành 6106. Mã FIPS hạt LA 037 biến thành 37 (nhầm sang bang Bắc Carolina)!

3. Chạm Giới Hạn Dòng Của Phần Mềm

Nếu dữ liệu dừng ở dòng thứ **65.536** (giới hạn Excel `.xls` cũ) → Dữ liệu đã bị cắt cụt!

Thực tế: Y tế Anh từng mất hàng ngàn mẫu xét nghiệm Covid-19 vì lỗi này.

4. Bất Nhất Định Dạng Ngày Tháng

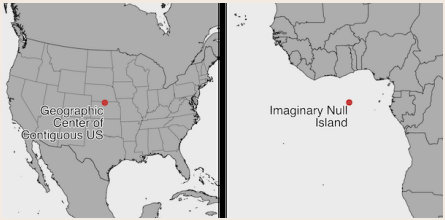
Nhầm giữa chuẩn Mỹ `MM/DD/YYYY` và Quốc tế `DD/MM/YYYY`.

Xuất hiện ngày mặc định hệ thống (1/1/1900, 1970) hoặc số thứ tự nội bộ Excel (43891).

ẢO GIÁC ĐỊA LÝ: BẪY GEOCODING SAI LỆCH

Khi chuyển đổi địa chỉ IP hoặc tọa độ thành điểm bản đồ, thuật toán Geocoding tự động có thể sinh ra bẫy chết người:

1. **Trang trại Bắc Kansas (Alberto Cairo)**
   - Một bản đồ từng chỉ ra cư dân vùng nông thôn Bắc Kansas xem web người lớn nhiều nhất nước Mỹ.
   - **Sự thật:** Hàng triệu IP ẩn danh (VPN) không xác định vị trí bị tự động gán vào **tâm địa lý của lục địa Mỹ** (tình cờ trúng nông trại này).
2. **Đảo ảo "Null Island"** $(0, 0)$
   - Dữ liệu lỗi tọa độ bị gán về giao điểm Xích đạo và Kinh tuyến gốc giữa Đại Tây Dương (thực chất chỉ là một phao đo thời tiết).



Hình 3.4: Bẫy tâm địa lý Kansas (trái) & Null Island tọa độ (0,0) (phải).

THỰC TRẠNG PHŨ PHÀNG CỦA BẢNG DỮ LIỆU THÔ

1. **Trùng lặp & Khoảng trắng thừa (Whitespaces)**
   - Khoảng trắng vô hình ở cuối chuỗi (`"Brazil "` vs `"Brazil"`) khiến máy tính coi đây là 2 quốc gia khác nhau khi gom nhóm.
2. **Tách đơn vị đo khỏi cột số**
   - Xóa bỏ ký hiệu `$`, dấu phẩy, `kg`, `%` (`282,805a` → 282805) để đưa văn bản (căn trái) về số thực thụ (căn phải).
3. **Cẩn trọng khi Tìm & Thay thế (Find & Replace)**
   - **Bài toán:** 169 thị trấn Connecticut thừa chữ `"town"` (`Hartford town`, `Newtown town`).
   - **Bẫy:** Thay `"town"` → `Newtown` bị biến thành `New`!
   - **Chuẩn:** Phải tìm chính xác chuỗi `" town"` **(có dấu cách phía trước)**.

Year	City	Amount
1990	New York City	$1,123,456.00
1995-96		2.2 mil
2000s	NYC	No data
2020	New_York	50000001

Hình 4.1: Bản phác thảo các lỗi định dạng kinh điển của dữ liệu thô.

TÁI CẤU TRÚC BẢNG: TRANSPOSE, SPLIT & COMBINE

1. Xoay Trục Dữ Liệu: Transpose (Hàng ↔ Cột)

Mâu thuẫn góc nhìn:

- Khi trình bày **Bảng (Table)** cho người đọc: Thời gian xếp **nằm ngang** theo cột (2000 | 2010 | 2020).
- Khi vẽ **Biểu đồ đường**: Phần mềm yêu cầu thời gian phải chạy **thẳng đứng** theo cột đầu tiên từ trên xuống dưới.

→ Kỹ thuật **Transpose** giúp đảo ngược ma trận Hàng ↔ Cột tức thời mà không cần nhập lại dữ liệu.

2. Tách Cột & Gộp Cột

Tách cột:

- Khi nhiều thực thể bị nhét chung vào 1 ô:
- `300 Summit St, Hartford CT--06106`
- Dùng dấu phân cách (`,`, khoảng trắng, `--`) tách thành 4 cột riêng: `Street | City | State | Zip`.

Gộp cột :

- Ngược lại, khi nạp vào công cụ bản đồ, nối các cột địa chỉ rời rạc thành một chuỗi duy nhất có dấu phẩy phân cách.

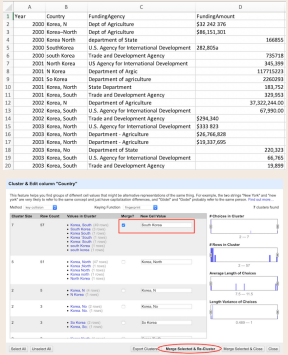
GOM CỤM CHUẨN HÓA TÊN GỌI

Thực tế dữ liệu viện trợ Mỹ:

- Chỉ riêng 2 quốc gia Triều Tiên và Hàn Quốc nhưng xuất hiện tới **26 cách viết khác nhau**: `Korea, N`, `Korea-North`, `SouthKorea`, `So Korea`, `Korea, South`...
- Cơ quan tài trợ sai chính tả: `Dept of Agriculture`, `Department of Argic`...

Thuật toán Gom cụm thông minh:

- **Key Collision:** Chuẩn hóa chữ hoa/thường, xóa dấu câu, sắp xếp lại từ khóa. Tốc độ rất cao, quét tập dữ liệu lớn.
- **Nearest Neighbor:** Tính khoảng cách chỉnh sửa giữa các chuỗi để bắt các lỗi chính tả tinh vi.



	A	B	C	D
1	Year	Country	FundingAgency	FundingAmount
2		2000 Korea, N	Dept of Agriculture	$32 242 376
3		2000 Korea-North	Dept of Agriculture	$86,151,301
4		2000 Korea North	department of State	166855
5		2000 SouthKorea	U.S. Agency for International Development	282,805a
6		2000 south Korea	Trade and Development Agency	735718
7		2001 North Korea	US Agency for International Development	345,399
8		2001 N Korea	Department of Agric	11771523
9		2001 So Korea	Department of agriculture	2260393
10		2001 Korea, North	State Department	183,752
11		2001 Korea, South	Trade and Development Agency	123,053
12		2002 Korea, N	Department of Agriculture	37,322,244.00
13		2002 Korea, South	U.S. Agency for International Development	67,990.00
14		2002 Korea, South	Trade and Development Agency	$296,340
15		2003 Korea, North	U.S. Agency for International Development	$333 823
16		2003 Korea, North	Department - Agriculture	$26,766,828
17		2003 Korea, North	Department - Agriculture	$19,337,695
18		2003 Korea, No	Department of State	220,323
19		2003 Korea, South	U.S. Agency for International Development	66,765
20		2003 Korea, South	Trade and Development Agency	19,859

Hình 4.11: Dữ liệu thô lộn xộn & Hình 4.18: Giao diện gom cụm về 1 tên.

TRUNG BÌNH (MEAN) VS. TRUNG VỊ (MEDIAN)

Chọn sai đại lượng sẽ bóp méo hoàn toàn câu chuyện:

- **Mean (Trung bình):** Rất nhạy cảm, dễ bị kéo lệch bởi ngoại lai.
- **Median (Trung vị):** Giá trị chính giữa, kháng nhiễu tuyệt đối.

1. Thay Đổi Phần Trăm (Percent Change)

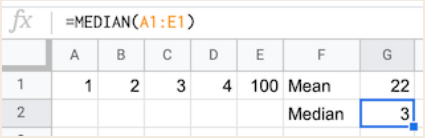
Biến thiên tương đối so với giá trị ban đầu:

$$\Delta\% = \frac{V_{\text{mới}} - V_{\text{cũ}}}{|V_{\text{cũ}}|} \times 100\%$$

2. Chênh Lệch Điểm Phần Trăm (Percentage Point)

Phép trừ số học giữa hai số tỷ lệ %:

Điểm % = Tỷ lệ Mới − Tỷ lệ Cũ



Hình 5.1: Minh họa Mean nhảy vọt lên 22 trong khi Median giữ vững ở 3.

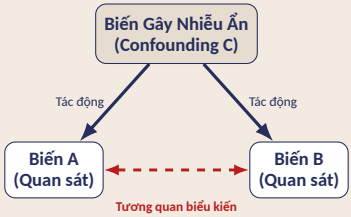
TƯƠNG QUAN KHÔNG ĐỒNG NGHĨA VỚI NHÂN QUẢ

Cực kỳ thận trọng với các động từ mang tính áp đặt: *"dẫn đến" (leads to), "thúc đẩy" (promotes), "gây ra" (causes).*

- **Tương quan (Correlation):** Hai biến số cùng biến thiên trên biểu đồ (ví dụ: tuổi thọ càng cao thì tỷ lệ sinh càng thấp).
- **Nhân quả (Causation):** Biến độc lập trực tiếp tạo ra sự thay đổi ở biến phụ thuộc.

3 bước bắt buộc để khẳng định Quan hệ Nhân quả:

1. Chứng minh có **tương quan thống kê rõ rệt**.
2. Xây dựng **lý thuyết cơ chế tác động** thuyết phục.
3. **Cô lập hoàn toàn mọi biến gây nhiễu (Confounding variables)** – yếu tố ẩn tác động đồng thời lên cả hai biến.



Sơ đồ tam giác: A và B tương quan chỉ vì cùng bị C chi phối!

CÁC PHƯƠNG PHÁP CHUẨN HÓA & NGOẠI LỆ

Các kỹ thuật chuẩn hóa chuyên sâu khác:

- **1. Điều chỉnh theo lạm phát:** Không thể so thu nhập $10.000 năm 1970 với năm 2020. Phải quy đổi từ số danh nghĩa sang sức mua thực tế.
- **2. Điều chỉnh theo mùa vụ:** Loại bỏ biến động chu kỳ tự nhiên (du lịch mùa hè, bán lẻ dịp Giáng sinh) để thấy xu hướng thực chất.
- **3. Chỉ số hóa:** Đưa các biến có đơn vị khác nhau về cùng mốc chuẩn Base 100 hoặc độ lệch chuẩn.

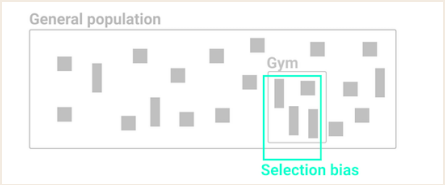
Khi Nào KHÔNG CẦN Chuẩn Hóa?

Khi biến số bản thân nó đã là một **đại lượng đo lường trên thang quy chiếu chung**:

- **Độ tuổi trung vị (Median Age):** Con người ở mọi thành phố đều sống trong thang tuổi 0–120, có thể so sánh trực tiếp.
- **Thu nhập hộ gia đình trung vị:** Xét trong cùng 1 năm và 1 đơn vị tiền tệ có thể đối chiếu giữa các vùng mà không cần chia theo đầu người!

THIÊN VỊ CHỌN MẪU & KHÔNG PHẢN HỒI

1. **Thiên vị chọn mẫu**
   - Mẫu được chọn khác biệt có hệ thống so với tổng thể.
   - **Ví dụ:** Đứng trước cửa phòng Gym để đo chiều cao ngẫu nhiên → kết luận sai rằng dân số cao vượt trội!
2. **Thiên vị không phản hồi**
   - Người từ chối trả lời khác biệt người trả lời.
   - **Thực tế:** Census 2020 trong đại dịch, người nghèo ít phản hồi → thu nhập trung vị bị đội lên cao giả tạo.
3. **Thiên vị tự lựa chọn**
   - Xảy ra khi đánh giá hiệu quả chương trình nơi người tham gia **tự nguyện đăng ký** (giảm cân, học bổng).
   - **So sánh SAI:** So sánh người không tham gia (Nhóm A) với người tự đăng ký (Nhóm B).
   - *Lý do:* Nhóm B vốn đã có **động lực và ý thức cao hơn hẳn** Nhóm A!



Hình 5.2: Khung Gym chỉ toàn người cao so với tổng thể chung.