Tháng 10, 2026

PHẦN 1 • BÁO CÁO CHUYÊN ĐỀ

NỀN TẢNG DỮ LIỆU

THU THẬP, LÀM SẠCH & CHUẨN HÓA

Từ Dữ Liệu Thô Đến Phép So Sánh Công Bằng (Chương 3, 4, 5)

Thuyết trình: **Người 1** • Tác phẩm: *Hands-On Data Visualization* (Jack Dougherty & Ilya Ilyankou)

NỘI DUNG TRÌNH BÀY (OUR CONTENTS)

01. CHƯƠNG 3

Tìm Kiếm & Phản Biện

- Triết lý: Dữ liệu không trung lập
- 5 câu hỏi định hướng nghiên cứu
- Ranh giới Public vs. Private
- Kỹ thuật Masking & Aggregating
- Quản trị nguồn & Bẫy Null Island

02. CHƯƠNG 4

Làm Sạch Dữ Liệu Bẩn

- Thực trạng phũ phàng dữ liệu thô
- Khoảng trắng & Bẫy " town"
- Tái cấu trúc bảng (Transpose)
- Tách cột (Split) & Gộp cột
- Gom cụm (Clustering) tên gọi

03. CHƯƠNG 5

Tạo Phép So Sánh

- Ngôn từ: Mean vs. Median
- % Thay đổi vs. Điểm %
- Tương quan ≠ Quan hệ nhân quả
- Chuẩn hóa dữ liệu (VMT rate)
- Cảnh giác 3 bẫy thiên vị mẫu

PHẦN 1 • MỤC 01

TÌM KIẾM & PHẢN BIỆN DỮ LIỆU

Chương 3: Find and Question Your Data

"Dữ liệu không tự nhiên sinh ra từ hư không,
và những con số không bao giờ hoàn toàn trung lập."

DỮ LIỆU KHÔNG BAO GIỜ TRUNG LẬP

1. Sự ngộ nhận về "Tính khách quan" (Data Objectivity)

- Nhiều người lầm tưởng *"con số không biết nói dối"*.
- Thực tế: Dữ liệu luôn do con người thu thập vì mục đích cụ thể.
- Chịu chi phối sâu sắc bởi bối cảnh lịch sử và cấu trúc quyền lực.

2. Góc nhìn từ *Data Feminism* (D'Ignazio & Klein, 2020)

- Khi tiếp cận bộ dữ liệu, hãy luôn tự hỏi:
  1. *Câu chuyện của ai đang được kể lại?* (Whose stories?)
  2. *Góc nhìn của ai đang bị bỏ qua hoặc im lặng?*



Sơ đồ Tảng băng trôi: Dữ liệu luôn có phần chìm chi phối.

5 CÂU HỎI ĐỊNH HƯỚNG: CÂU HỎI CỐT LÕI

1. Câu hỏi chính xác bạn muốn trả lời là gì?

- Đừng gõ từ khóa ngẫu nhiên lên Google.
- **Quy tắc:** Viết thành một câu hỏi rõ ràng có dấu **?** ở cuối để định hình tư duy, tránh não bộ nhảy cóc sang kết luận có sẵn.

2. Sẵn sàng điều chỉnh câu hỏi khi nghiên cứu

- Từ câu hỏi ngây thơ: *"Điểm thi trường công Connecticut thập niên 1960 là bao nhiêu?"* ($\rightarrow$ thời đó chưa có thi chuẩn hóa).
- Đổi thành câu hỏi sâu sắc: *"Khi nào người mua nhà bắt đầu biết điểm thi và nó tác động thế nào đến giá bất động sản?"*

Case Study: Đại Dịch Opioid (Washington Post, 2019)

Câu hỏi điều tra: Có bao nhiêu viên thuốc giảm đau kê đơn gửi tới từng quận của Mỹ (theo đầu người)? Tập đoàn nào chịu trách nhiệm?

Phát hiện từ cơ sở dữ liệu DEA ARCOS:

- Phân phối hơn **100 tỷ viên thuốc** (2006–2014).
- Quận nông thôn Appalachia nhận > 150 **viên/người/năm**.
- Chỉ **6 tập đoàn** chiếm $> 75\%$ tổng lượng cung ứng.

TỔ CHỨC CÔNG BỐ & CẤP ĐỘ PHÂN GIẢI (CENSUS)

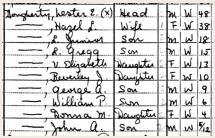
2. Tổ chức nào có khả năng thu thập dữ liệu này?

- Cơ quan công quyền: Cấp địa phương, bang, liên bang.
- Phi chính phủ: Viện hàn lâm, cơ quan báo chí, NGO, tập đoàn.

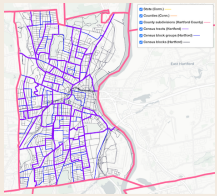
3. Dữ liệu có sẵn ở cấp độ phân giải nào?

- **Cá nhân (Disaggregated):** Chi tiết cao nhưng chạm giới hạn quyền riêng tư (Luật liên bang Census bảo mật hồ sơ cá nhân **72 năm**, ví dụ sổ viết tay 1940).
- **Tổng hợp (Aggregated):** Phân cấp địa lý Census:

  State → County → Town → Census Tract → Block Group



Dougherty, Harter E. (X)	Head		M	W	48
Hazel L.	Wife		F	W	38
R. Jeanne	Son		M	W	18
R. Gregg	Son		M	W	15
V. Elizabeth	Daughter		F	W	12
Beverley J.	Daughter		F	W	10
George A.	Son		M	W	9
William P.	Son		M	W	4
Donna M.	Daughter		F	W	4
John A.	Son		M	W	8/12



Hình 3.1: Sổ Census cá nhân 1940 & Hình 3.2: Lớp phân cấp Hartford.

LẦN DẤU FOOTNOTES & KHOẢNG TRỐNG DỮ LIỆU

4. Các ấn phẩm trước đây đã dùng dữ liệu tương tự chưa?

- Lần theo **chú thích chân trang (Footnotes)** để tìm kho lưu trữ gốc, cập nhật số liệu mới nhằm so sánh theo thời gian.

5. Điều gì xảy ra nếu CHƯA AI từng thu thập dữ liệu?

- Sự vắng mặt của dữ liệu không phải vô tình, mà phản ánh **bất bình đẳng quyền lực**.
- Cấu trúc quyền lực thường **chỉ đếm những gì họ coi trọng**.
- **Bài học:** Nếu dữ liệu chưa tồn tại, việc chỉ ra *khoảng trống dữ liệu (Missing Dataset)* là đóng góp lớn.

Case Study: Serena Williams & Tử Vong Thai Sản (2017)

Sau biến chứng nguy hiểm tính mạng khi sinh nở, Serena Williams lên tiếng: Phụ nữ da đen có nguy cơ tử vong thai sản **cao gấp** > 3 **lần** phụ nữ da trắng.

Sự thật bàng hoàng khi báo chí điều tra:

- Hệ thống y tế Mỹ theo dõi rất sát bệnh tim hay thay khớp háng.
- Nhưng **không hề có hệ thống quốc gia theo dõi biến chứng thai sản**!

DỮ LIỆU CÔNG KHAI (PUBLIC) VS. RIÊNG TƯ (PRIVATE)

Khía cạnh	Khu vực Tư nhân (Big Tech)	Khu vực Công (Chính phủ)
Thực trạng thu thập	**Chủ nghĩa tư bản giám sát** (Shoshana Zuboff): Google (cookie), Amazon (Alexa), Meta (theo dõi hành vi).	Dữ liệu công dân; công chúng dùng **Đạo luật Tự do Thông tin (FOIA)** / Sunshine Laws để giám sát.
Dữ liệu cấm công khai cá nhân	Phụ thuộc chính sách nội bộ và đạo luật người tiêu dùng (CCPA).	• **HIPAA:** Bảo mật hồ sơ bệnh án. • **FERPA:** Bảo mật điểm học tập. → *Bắt buộc ẩn danh hóa & gom cụm.*
Dữ liệu cá nhân công khai vì cộng đồng	Dữ liệu di chuyển tổng hợp (Apple Mobility Index trong đại dịch).	1. Đóng góp tài chính bầu cử (FEC). 2. Hồ sơ sở hữu và giá trị bất động sản. 3. Lương lãnh đạo quỹ phi lợi nhuận (IRS 990). 4. Hồ sơ cảnh sát dùng vũ lực (The Force Report).

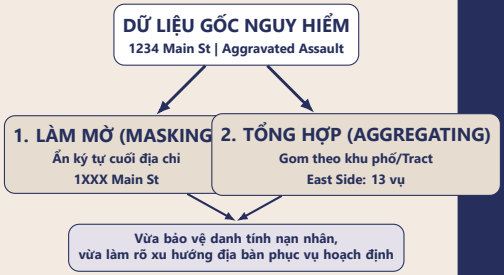
BẢO VỆ DANH TÍNH: LÀM MỜ & TỔNG HỢP

Câu Hỏi Đạo Đức Cốt Lõi

Ngay cả khi dữ liệu cá nhân là **hợp pháp và công khai**, việc tái xuất bản lên bản đồ có gây hại cho nạn nhân nhiều hơn lợi ích cộng đồng?

Tình huống: Bản đồ cuộc gọi 911 về bạo lực

- Nếu định vị chính xác địa chỉ nhà nạn nhân, bạn có thể gây tổn thương tâm lý hoặc nguy cơ trả thù.
- Cần chuyển hóa dữ liệu qua 2 kỹ thuật bảo vệ.



QUY TẮC QUẢN TRỊ NGUỒN DỮ LIỆU CHUẨN

Để đảm bảo **tính minh bạch, độ tin cậy và khả năng tái lập (Replicability)**, hãy rèn luyện 3 thói quen ngay khi tải file:

1. Đặt tên file có ý nghĩa (Meaningful Filenames)

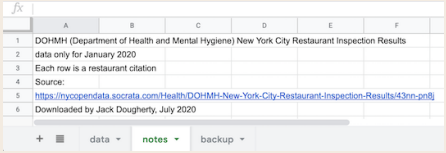
- **Tránh:** `data.csv`, `download.xlsx`, `file(1).csv`.
- **Chuẩn:** Nguồn + Chủ đề + Ngày `YYYY-MM-DD` (chữ thường, gạch nối): `eurostat-co2-emissions-2020-05-01.xlsx`.

2. Tạo tab `notes` riêng biệt bên trong bảng tính

- Ghi rõ cơ quan ban hành, URL tải, định nghĩa nhãn viết tắt, người tải và ngày cập nhật.

3. Tạo tab `backup` bất khả xâm phạm

- Giữ nguyên dữ liệu gốc, thao tác làm sạch ở tab `data`.



Hình 3.3: Cấu trúc 3 tab chuẩn: data | notes | backup trong bảng tính.

4 DẤU HIỆU DỮ LIỆU LỖI KINH ĐIỂN (QUARTZ GUIDE)

1. Missing Values Nhập Sai

Ô trống (`null/blank`) có ý nghĩa khác số `0`.

Cảnh báo: Người nhập điền `0`, `-1`, `-999` để báo khuyết làm sai lệch hoàn toàn hàm `SUM`, `AVERAGE`!

2. Mất Số 0 Dẫn Đầu (Leading Zeros)

Xảy ra khi phần mềm tự ép kiểu Text sang Number.

Hậu quả: Mã Zip `06106` bị biến thành `6106`. Mã FIPS hạt LA `037` biến thành `37` (nhầm sang bang Bắc Carolina)!

3. Chạm Giới Hạn Dòng Của Phần Mềm

Nếu dữ liệu dừng ở dòng thứ **65.536** (giới hạn Excel `.xls` cũ) → Dữ liệu đã bị cắt cụt!

Thực tế: Y tế Anh từng mất hàng ngàn mẫu xét nghiệm Covid-19 vì lỗi này.

4. Bất Nhất Định Dạng Ngày Tháng

Nhầm giữa chuẩn Mỹ `MM/DD/YYYY` và Quốc tế `DD/MM/YYYY`.

Xuất hiện ngày mặc định hệ thống (`1/1/1900`, `1970`) hoặc số thứ tự nội bộ Excel (`43891`).

ẢO GIÁC ĐỊA LÝ: BẪY GEOCODING SAI LỆCH

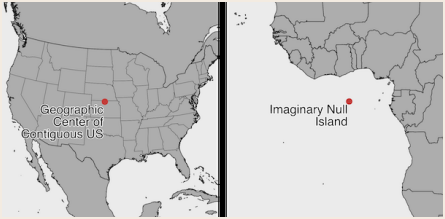
Khi chuyển đổi địa chỉ IP hoặc tọa độ thành điểm bản đồ, thuật toán Geocoding tự động có thể sinh ra bẫy chết người:

1. Trang trại Bắc Kansas (Alberto Cairo)

- Một bản đồ từng chỉ ra cư dân vùng nông thôn Bắc Kansas xem web người lớn nhiều nhất nước Mỹ.
- **Sự thật:** Hàng triệu IP ẩn danh (VPN) không xác định vị trí bị tự động gán vào **tâm địa lý của lục địa Mỹ** (tình cờ trúng nông trại này).

2. Đảo ảo "Null Island" $(0, 0)$

- Dữ liệu lỗi tọa độ bị gán về giao điểm Xích đạo và Kinh tuyến gốc giữa Đại Tây Dương (thực chất chỉ là một phao đo thời tiết).



Hình 3.4: Bẫy tâm địa lý Kansas (trái) & Null Island tọa độ (0,0) (phải).

ĐỌC SÂU METADATA: SAI SỐ & KIẾN TẠO XÃ HỘI

1. Nhãn Cột Nghĩa Là Gì?

• Đơn vị đo lường: Cột `Elevation` tính bằng mét hay feet?

• Phạm vi khảo sát: Cột `Income` tính theo cá nhân, gia đình hay hộ gia đình? Là số trung bình (`Mean`) hay trung vị (`Median`)?

2. Sai Số Lấy Mẫu (Margin of Error)

• Dữ liệu lấy mẫu luôn đi kèm khoảng bất định.

• Khảo sát ACS cấp khu vực (4.000 dân) báo thu nhập $\$50.000$ nhưng **sai số** $\pm\$25.000$ (thực tế từ $\$25.000$ đến $\$75.000$ $\rightarrow$ vô nghĩa nếu không chú thích).

3. Kiến Tạo Xã Hội

• Các danh mục phân loại thay đổi theo thời gian và chính trị.

• Điều tra Census Mỹ: Tách *Native White* và *Foreign-born White* (1930) $\rightarrow$ đổi *Negro* thành *Black* (1980) $\rightarrow$ cho phép chọn đa chủng tộc (2000).

PHẦN 1 • MỤC 02

KỸ THUẬT LÀM SẠCH DỮ LIỆU BẨN

Chương 4: Clean Up Messy Data

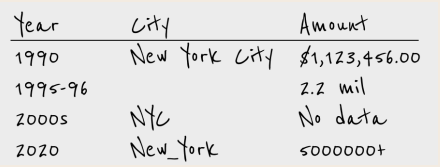
"Đừng ngạc nhiên nếu bạn dành nhiều thời gian để dọn dẹp dữ liệu
hơn là phân tích và vẽ biểu đồ."

THỰC TRẠNG PHŨ PHÀNG CỦA BẢNG DỮ LIỆU THÔ

Hiếm khi dữ liệu tải về có thể vẽ đồ thị ngay. Dữ liệu thô luôn chứa đầy lỗi định dạng:

Year	City	Amount
1990	New York City	$1,123,456.00
1995-96	*(Trống)*	2.2 mil
2000s	NYC	No data
2020	New_York	5000000+

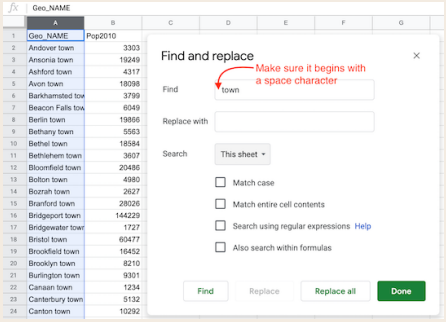
- **Cột Year:** Trộn lẫn năm, khoảng năm và thập kỷ.
- **Cột City:** Ô trống, viết tắt tùy tiện, dấu gạch nối.
- **Cột Amount:** Ký hiệu $, chữ `mil`, `No data`, dấu + khiến máy tính hiểu nhầm cả cột thành chuỗi văn bản (Text)!



Hình 4.1: Bản phác thảo các lỗi định dạng kinh điển của dữ liệu thô.

XỬ LÝ TRÙNG LẶP, KHOẢNG TRẮNG & BẪY CHUỖI

1. **Trùng lặp & Khoảng trắng thừa (Whitespaces)**
   - Khoảng trắng vô hình ở cuối chuỗi (`"Brazil "` vs `"Brazil"`) khiến máy tính coi đây là 2 quốc gia khác nhau khi gom nhóm.
2. **Tách đơn vị đo khỏi cột số**
   - Xóa bỏ ký hiệu $, dấu phẩy, kg, % (`282,805a` → 282805) để đưa văn bản (căn trái) về số thực thụ (căn phải).
3. **Cẩn trọng khi Tìm & Thay thế (Find & Replace)**
   - **Bài toán:** 169 thị trấn Connecticut thừa chữ `"town"` (`Hartford town`, `Newtown town`).
   - **Bẫy:** Thay `"town"` → `Newtown` bị biến thành `New`!
   - **Chuẩn:** Phải tìm chính xác chuỗi `" town"` **(có dấu cách phía trước)**.



Hình 4.3: Hướng dẫn tìm kiếm có dấu cách: "Make sure it begins with a space".

TÁI CẤU TRÚC BẢNG: TRANSPOSE, SPLIT & COMBINE

1. Xoay Trục Dữ Liệu: Transpose (Hàng ↔ Cột)

Mâu thuẫn góc nhìn (Stephen Few):

- Khi trình bày **Bảng (Table)** cho người đọc: Thời gian xếp **nằm ngang** theo cột (2000 | 2010 | 2020).
- Khi vẽ **Biểu đồ đường (Line Chart)**: Phần mềm yêu cầu thời gian phải chạy **thẳng đứng** theo cột đầu tiên từ trên xuống dưới.

→ Kỹ thuật **Transpose** giúp đảo ngược ma trận Hàng ↔ Cột tức thời mà không cần nhập lại dữ liệu.

2. Tách Cột (Split) & Gộp Cột (Combine)

Tách cột (Splitting):

- Khi nhiều thực thể bị nhét chung vào 1 ô:
- `300 Summit St, Hartford CT--06106`
- Dùng dấu phân cách (`,`, khoảng trắng, `--`) tách thành 4 cột riêng: `Street` | `City` | `State` | `Zip`.

Gộp cột (Concatenating):

- Ngược lại, khi nạp vào công cụ bản đồ (Geocoding), nối các cột địa chỉ rời rạc thành một chuỗi duy nhất có dấu phẩy phân cách.

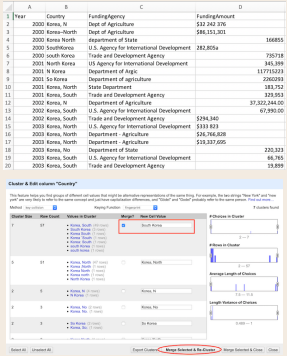
GOM CỤM CHUẨN HÓA TÊN GỌI (CLUSTERING)

Thực tế dữ liệu viện trợ Mỹ (Greenbook):

- Chỉ riêng 2 quốc gia Triều Tiên và Hàn Quốc nhưng xuất hiện tới **26 cách viết khác nhau**: `Korea, N`, `Korea-North`, `SouthKorea`, `So Korea`, `Korea, South`...
- Cơ quan tài trợ sai chính tả: `Dept of Agriculture`, `Department of Argic`...

Thuật toán Gom cụm thông minh (Clustering):

- **Key Collision (Fingerprinting):** Chuẩn hóa chữ hoa/thường, xóa dấu câu, sắp xếp lại từ khóa. Tốc độ rất cao, quét tập dữ liệu lớn.
- **Nearest Neighbor:** Tính khoảng cách chỉnh sửa giữa các chuỗi để bắt các lỗi chính tả tinh vi.



	A	B	C	D
1	Year	Country	FundingAgency	FundingAmount
2		2000 Korea, N	Dept of Agriculture	$32 242 376
3		2000 Korea-North	Dept of Agriculture	$86,151,301
4		2000 Korea North	department of State	166855
5		2000 SouthKorea	U.S. Agency for International Development	282,805a
6		2000 south Korea	Trade and Development Agency	735718
7		2001 North Korea	US Agency for International Development	341,399
8		2001 N Korea	Department of Aigic	117715233
9		2001 So Korea	Department of agriculture	2260293
10		2001 Korea, North	State Department	183,752
11		2001 Korea, South	Trade and Development Agency	329,953
12		2002 Korea, N	Department of Agriculture	37,322,244.00
13		2002 Korea, South	U.S. Agency for International Development	67,990.00
14		2002 Korea, South	Trade and Development Agency	$294,340
15		2003 Korea, North	U.S. Agency for International Development	$333 823
16		2003 Korea, North	Department - Agriculture	$26,766,828
17		2003 Korea, North	Department - Agriculture	$19,337,695
18		2003 Korea, No	Department of State	220,323
19		2003 Korea, South	U.S. Agency for International Development	86,765
20		2003 Korea, South	Trade and Development Agency	19,899

Hình 4.11: Dữ liệu thô lộn xộn & Hình 4.18: Giao diện gom cụm về 1 tên.

PHẦN 1 • MỤC 03

TẠO PHÉP SO SÁNH CÓ Ý NGHĨA

Chương 5: Make Meaningful Comparisons

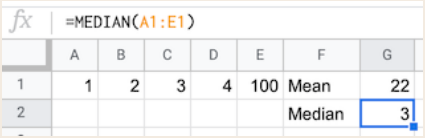
"Trọng tâm của tư duy định lượng nằm ở một câu hỏi duy nhất: So sánh với cái gì? (Compared to what?)"

– Edward Tufte

TRUNG BÌNH (MEAN) VS. TRUNG VỊ (MEDIAN)

Chọn sai đại lượng sẽ bóp méo hoàn toàn câu chuyện:

- **Mean (Trung bình):** Rất nhạy cảm, dễ bị kéo lệch bởi ngoại lai.
- **Median (Trung vị):** Giá trị chính giữa, kháng nhiễu tuyệt đối.



Hình 5.1: Minh họa Mean nhảy vọt lên 22 trong khi Median giữ vững ở 3.

Tình huống	Dãy số khảo sát	Mean	Median
Dãy chuẩn đồng đều	1, 2, 3, 4, 5	**3**	**3**
Xuất hiện ngoại lai	1, 2, 3, 4, 100	**22** *(Ảo)*	**3** *(Thực)*

Bài Học Kinh Điển

"Khi tỷ phú bước vào phòng, tính Mean ai cũng thành triệu phú, nhưng Median không ai giàu lên cả." → Dùng **Median** cho thu nhập, giá nhà.

% THAY ĐỔI VS. ĐIỂM PHẦN TRĂM

1. Thay Đổi Phần Trăm (Percent Change)

Biến thiên tương đối so với giá trị ban đầu:

$$\Delta\% = \frac{\mathbf{V}_{\text{mới}} - \mathbf{V}_{\text{cũ}}}{|\mathbf{V}_{\text{cũ}}|} \times \mathbf{100}\%$$

2. Chênh Lệch Điểm Phần Trăm (Percentage Point)

Phép trừ số học giữa hai số tỷ lệ %:

Điểm % = Tỷ lệ Mới − Tỷ lệ Cũ

Bẫy Truyền Thông: Tăng Thuế Tiêu Dùng (Sales Tax)

Chính quyền tăng thuế từ **5% lên 6%** và tuyên bố: *"Thuế chỉ tăng có 1% thôi!"*

→ **Tuyên bố này hoàn toàn SAI LỆCH!**

- **Nói đúng 1:** Tăng **1 điểm phần trăm** ($6\% - 5\% = 1$ pp).
- **Nói đúng 2:** Gánh nặng thuế thực tế đã **tăng 20%**:

$$\frac{\mathbf{6}\% - \mathbf{5}\%}{\mathbf{5}\%} = \frac{\mathbf{1}\%}{\mathbf{5}\%} = \mathbf{20}\%$$

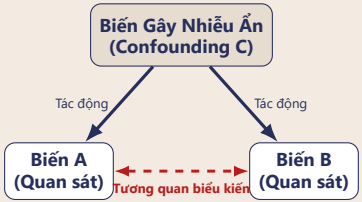
TƯƠNG QUAN KHÔNG ĐỒNG NGHĨA VỚI NHÂN QUẢ

Cực kỳ thận trọng với các động từ mang tính áp đặt: *"dẫn đến" (leads to), "thúc đẩy" (promotes), "gây ra" (causes).*

- **Tương quan (Correlation):** Hai biến số cùng biến thiên trên biểu đồ (ví dụ: tuổi thọ càng cao thì tỷ lệ sinh càng thấp).
- **Nhân quả (Causation):** Biến độc lập trực tiếp tạo ra sự thay đổi ở biến phụ thuộc.

3 bước bắt buộc để khẳng định Quan hệ Nhân quả:

1. Chứng minh có **tương quan thống kê rõ rệt**.
2. Xây dựng **lý thuyết cơ chế tác động** thuyết phục.
3. **Cô lập hoàn toàn mọi biến gây nhiễu (Confounding variables)** – yếu tố ẩn tác động đồng thời lên cả hai biến.



Sơ đồ tam giác: A và B tương quan chỉ vì cùng bị C chi phối!

CASE STUDY: ĐÂU LÀ TIỂU BANG AN TOÀN NHẤT?

Phương pháp	Top 3 Bang Dẫn Đầu	Đánh giá tính công bằng
Lần 1: Số đếm thô	1. Washington D.C. (31) 2. Rhode Island (59) 3. Vermont (68)	**Bất công:** Các nơi này cực kỳ ít dân so với California hay Texas! Không phản ánh mức độ an toàn.
Lần 2: Chuẩn hóa theo Dân số $\frac{\text{Số ca}}{\text{Dân số}} \times 100.000$	1. Washington D.C. $(4, 4)$ 2. New York $(4, 8)$ 3. Massachusetts $(5, 2)$	**Chưa chuẩn:** Vùng đô thị Đông Bắc người dân chủ yếu đi bộ và tàu điện ngầm, rất ít lái xe!
Lần 3: Chuẩn hóa theo Quãng đường (VMT) $\frac{\text{Số ca}}{\text{Triệu dặm xe chạy}} \times 100$	1. Massachusetts $(0, 54)$ 2. Minnesota $(0, 63)$ 3. New Jersey $(0, 73)$	**Chính xác nhất:** *D.C. bị loại khỏi Top 5!* Thước đo này phản ánh sát nhất rủi ro thực tế khi tham gia giao thông.

CÁC PHƯƠNG PHÁP CHUẨN HÓA & NGOẠI LỆ

Các kỹ thuật chuẩn hóa chuyên sâu khác:

- **1. Điều chỉnh theo lạm phát (Real Dollars):** Không thể so thu nhập $10.000 năm 1970 với năm 2020. Phải quy đổi từ số danh nghĩa sang sức mua thực tế.
- **2. Điều chỉnh theo mùa vụ (Seasonal Adjustment):** Loại bỏ biến động chu kỳ tự nhiên (du lịch mùa hè, bán lẻ dịp Giáng sinh) để thấy xu hướng thực chất.
- **3. Chỉ số hóa (Indexing & Z-score):** Đưa các biến có đơn vị khác nhau về cùng mốc chuẩn Base 100 hoặc độ lệch chuẩn.

Khi Nào KHÔNG CẦN Chuẩn Hóa?

Khi biến số bản thân nó đã là một **đại lượng đo lường trên thang quy chiếu chung (Measured variables)**:

• **Độ tuổi trung vị (Median Age):** Con người ở mọi thành phố đều sống trong thang tuổi 0–120, có thể so sánh trực tiếp.

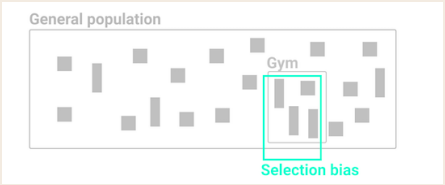
• **Thu nhập hộ gia đình trung vị (Median Income):** Xét trong cùng 1 năm và 1 đơn vị tiền tệ có thể đối chiếu giữa các vùng mà không cần chia theo đầu người!

THIÊN VỊ CHỌN MẪU & KHÔNG PHẢN HỒI

Ngay cả khi không cố tình *"chọn quả anh đào"* (cherry-picking), dữ liệu vẫn có thể bị bóp méo từ khâu lấy mẫu:

1. **Thiên vị chọn mẫu (Selection Bias)**
   - Mẫu được chọn khác biệt có hệ thống so với tổng thể.
   - *"Những gì bạn thấy phụ thuộc vào nơi bạn nhìn"* (Bergstrom & West).
   - **Ví dụ:** Đứng trước cửa phòng Gym để đo chiều cao ngẫu nhiên → kết luận sai rằng dân số cao vượt trội!

2. **Thiên vị không phản hồi (Non-response Bias)**
   - Người từ chối trả lời khác biệt người trả lời.
   - **Thực tế:** Census 2020 trong đại dịch, người nghèo ít phản hồi → thu nhập trung vị bị đội lên cao giả tạo.



Hình 5.2: Khung Gym chỉ toàn người cao so với tổng thể chung.

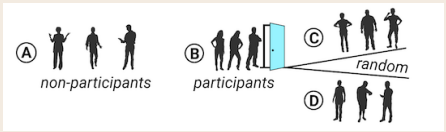
THIÊN VỊ TỰ LỰA CHỌN & CHIA MẪU NGẪU NHIÊN

3. Thiên vị tự lựa chọn (Self-selection Bias)

- Xảy ra khi đánh giá hiệu quả chương trình nơi người tham gia **tự nguyện đăng ký** (giảm cân, học bổng).
- **So sánh SAI:** So sánh người không tham gia (Nhóm A) với người tự đăng ký (Nhóm B).
- *Lý do:* Nhóm B vốn đã có **động lực và ý thức cao hơn hẳn** Nhóm A!

Giải pháp chuẩn (Randomized Trial):

- Lấy toàn bộ người đã tình nguyện đăng ký (Nhóm B – có cùng mức quyết tâm).
- **Chia ngẫu nhiên (Randomly split)** thành Nhóm C (phác đồ 1) và Nhóm D (phác đồ 2) để so sánh công bằng.



Hình 5.3: Không so A với B; Tách ngẫu nhiên B thành C và D.

HÀNH TRANG CỐT LÕI TRƯỚC KHI VẼ BIỂU ĐỒ

1. TÌM KIẾM & PHẢN BIỆN

Chương 3

- Viết câu hỏi rõ có dấu ?
- Tôn trọng quyền riêng tư (Masking, Aggregating)
- Quy tắc 3 tab: data, notes, backup
- Cảnh giác bẫy Null Island
- Đọc sâu sai số Metadata

2. LÀM SẠCH DỮ LIỆU

Chương 4

- Dọn sạch khoảng trắng thừa
- Bẫy có dấu cách `" town"`
- Xoay trục bảng (Transpose)
- Tách/gộp cột linh hoạt
- Gom cụm (Clustering) tên

3. PHÉP SO SÁNH

Chương 5

- Ưu tiên dùng Median
- Phân biệt Điểm % và %
- Tương quan $\neq$ Nhân quả
- Chuẩn hóa theo mẫu số đúng
- Tránh 3 bẫy thiên vị mẫu

Tiếp theo: Phần 2 – Trực Quan Hóa Biểu Đồ Thực Chiến (Chương 6 & 14)